

Universidad Yachay Tech

Maestría en Ciencia de Datos

Fundamentos de Ciencia de Datos

Taller: Adquisición, procesamiento y visualización de datos

Objetivo:

- Aprender a manipular datos en varios formatos y con varias herramientas.
- Realizar un análisis de datos exploratorio en un set de datos desconocido.
- Utilizar técnicas de visualización de datos para la exploración.
- Familiarizarse con librerías y herramientas avanzadas en ciencia de datos.

Duración aproximada:

4 horas

Prerrequisitos:

- Conocimiento de programación en Python
- Familiaridad con uso de conjuntos de datos
- Instalación de librerías

Materiales:

- El dataset a utilizar se llama **Online Retail Data Set** y puede ser encontrado en el siguiente link: <https://archive.ics.uci.edu/dataset/352/online+retail>

Instrucciones:

Parte 1: Adquisición y limpieza de datos

- Implementar un script que lea el archivo de datos
- Realizar la limpieza de los datos explicando la lógica de cada decisión
- Subir los datos limpios a una base de datos SQLite

Parte 2: EDA

- Realizar un análisis y una descripción (incluir como archivo de texto) de que información contiene el set de datos. ¿Qué puede decir o cómo puedes describir este set de datos?
- Realizar la lectura de los datos de la base de datos utilizando Python y transformando la tabla a un *dataframe* de pandas.
- Describir lo encontrado para cada uno de los campos
- ¿Qué meta-data se puede generar?

- Utilizar la documentación del dataset como referencia

Parte 3: Visualización

- Implementar tres técnicas de visualización que ayuden a entender el comportamiento del set de datos. Explorar opciones avanzadas de visualización. Describir textualmente cuál es la historia que cuentan las gráficas.
- Guardar todas las visualizaciones como archivos de imágenes en el mismo directorio.